

ACTIVIDAD 1

Se cargó el dataset Bank Marketing en Orange.

La variable objetivo (Target) seleccionada fue **y**, que indica si el cliente se suscribió a un depósito a plazo fijo (yes/no).

Las variables predictoras incluyen características socioeconómicas y de campaña del cliente.

En el análisis exploratorio (widgets Distributions y Feature Statistics), se observa que:

- La mayoría de los clientes no se suscribieron al depósito (no es la clase dominante).
- Entre las variables más influyentes:
 - Age: la mayoría de los clientes se encuentran entre los 30 y 40 años. Los más jóvenes y los mayores muestran menor tasa de suscripción.
 - Poutcome: los clientes cuyo resultado previo de campaña fue "success" tienen mayor probabilidad de suscribirse nuevamente.
 - Duration: las llamadas más largas tienden a correlacionarse con un resultado positivo ("yes").

Preprocesamiento de Datos

- Se utilizó el widget Select Columns para definir los roles:
 - Target: y
 - Features: todas las demás variables numéricas y categóricas.

División de Datos

Se realizó la división del conjunto de datos con 80 % para entrenamiento (training) y 20 % para prueba (testing), utilizando el widget Data Sampler.

4. Modelado y Entrenamiento

Se entrenaron tres modelos de clasificación:

- Regresión Logística
- Random Forest
- Naive Bayes

Todos los modelos se conectaron al widget Test and Score para evaluar su rendimiento utilizando Cross Validation con 10 folds estratificados.

Model	AUC	CA	F1	Prec	Recall	MCC
Logistic Regression	0.927	0.914	0.905	0.903	0.914	0.497
Random Forest	0.900	0.902	0.891	0.887	0.902	0.414
Naive Bayes	0.830	0.825	0.846	0.883	0.825	0.382

El modelo de Regresión Logística logra el mejor desempeño general, destacándose en todas las métricas principales (AUC, CA, F1, Precisión y Recall).

- TP (Verdaderos Positivos): 160
- TN (Verdaderos Negativos): 2851
- FP (Falsos Positivos): 79
- FN (Falsos Negativos): 206

El modelo logra altas tasas de acierto en la clase negativa (no) y un desempeño razonable en la clase positiva, lo que es coherente con el desbalance del dataset.

En el widget ROC Analysis, la Regresión Logística presenta la curva más cercana al vértice superior izquierdo, indicando el mejor equilibrio entre:

- TPR (True Positive Rate / Sensibilidad)
- FPR (False Positive Rate / Tasa de Falsos Positivos)

El Random Forest tiene un rendimiento similar, pero ligeramente inferior en AUC, mientras que Naive Bayes muestra menor capacidad discriminante.

En este caso, notamos que los falsos negativos son más costosos; porque estaríamos dejando pasar a personas que sí habrían contratado el depósito. Es decir, el modelo no las vería como potenciales clientes y el banco perdería oportunidades reales. Por lo tanto, se prioriza reducir los falsos negativos (FN). Esto implica mejorar el Recall (Sensibilidad), aunque implique tener más falsos positivos.

ACTIVIDAD 2

A) Cálculo de métricas

Datos: TP=350, FN=150, FP=100, TN=4400 (N=5000)

1. Precisión (Precision)

$$\text{Precision} = TP/(TP+FP) = 350/(350+100) = 350 / 450 = 7/9 = 0,7778$$

2. Exhaustividad (Recall / Sensibilidad)

$$\text{Exhaustividad} = TP/(TP+FN) = 350/(350+150) = 350 / 500 = 7/10 = 0,70$$

3. Exactitud (Accuracy)

$$\text{Accuracy} = (TP+TN)/N = 350 + 4400 = 5000 = 4750 / 5000 = 0,95$$

4. F1-score

$$F1 = 2 * \text{precisión} * \text{exhaustividad} / (\text{precisión} + \text{exhaustividad}) = 2 * (7/9 * 7/10) / (7/9 + 7/10) \\ = 98/133 = 14/19 = 0,7368$$

B) Análisis de impacto estratégico

1. Implicaciones de errores

- **Falso Positivo (FP):** el modelo predice “se va” pero en realidad permanece.
Consecuencia: gastar incentivos y esfuerzos de retención innecesarios en un cliente que no se iba a dar de baja (costo directo y oportunidad del equipo).
- **Falso Negativo (FN):** el modelo predice “permanece” pero en realidad se va.
Consecuencia: se pierde al cliente y el ingreso futuro asociado (ARPU, LTV), más posibles costos de re-adquisición si luego intentan recuperarlo.

2. Prioridad de métrica (cuando se busca minimizar incentivos innecesarios)

Si la dirección quiere minimizar a toda costa gastar en clientes que no iban a abandonar (reducir FP), la métrica más relevante es la Precisión (Precisión): mide qué proporción de los predichos como “se va” efectivamente se iban. Una mayor precisión implica menos falsos positivos por cada cliente marcado para retención, alineándose exactamente con el objetivo de no derrochar incentivos.